

**TRƯỜNG ĐẠI HỌC MỞ TP. HCM**  
**KHOA CÔNG NGHỆ THÔNG TIN**



**BÀI BÁO CÁO**  
**MÔN HỌC: PHÂN TÍCH DỮ LIỆU**

**TÊN ĐỀ TÀI:**

**XÂY DỰNG HỆ THỐNG GỢI Ý**  
**VÀ TÌM KIẾM NHẠC THÔNG MINH**  
**DỰA TRÊN PHÂN CỤM DỮ LIỆU**  
**VÀ ĐỘ TƯƠNG ĐỒNG NGỮ NGHĨA**

Giảng viên hướng dẫn: **Hồ Hương Thiên**

Sinh viên thực hiện:

|                                 |                     |
|---------------------------------|---------------------|
| <b>1. Trịnh Nguyễn Phi Long</b> | <b>- 2354050064</b> |
| <b>2. Mai Như Nguyệt</b>        | <b>- 2354050079</b> |
| <b>3. Nguyễn Thị Anh Thư</b>    | <b>- 2354050131</b> |

## MỤC LỤC

|                      |   |
|----------------------|---|
| I. GIỚI THIỆU.....   | 2 |
| II. MỤC TIÊU.....    | 3 |
| III. BỘ DỮ LIỆU..... | 4 |
| IV. PHÂN TÍCH.....   | 5 |
| V. KẾT LUẬN.....     | 6 |

## I. GIỚI THIỆU

### 1.1. Bối cảnh và tính cấp thiết

Trong bối cảnh bùng nổ của các nền tảng Spotify, người dùng đang đối mặt với vấn đề "Quá tải thông tin" (Information Overload). Một thách thức lớn tồn tại là khoảng cách ngữ nghĩa (Semantic Gap) giữa nhu cầu tìm kiếm của người dùng và siêu dữ liệu (Metadata) của bài hát. Người dùng thường có xu hướng tìm kiếm theo những đoạn lời bài hát (Lyrics) bất chợt nhớ ra, hoặc tìm kiếm theo tâm trạng trừu tượng, trong khi các công cụ tìm kiếm truyền thống chủ yếu dựa trên so khớp từ khóa chính xác (Exact Match) trên Tiêu đề bài hát.

### 1.2. Phát biểu bài toán

Đề án tập trung giải quyết 3 vấn đề cốt lõi:

- Sai lệch về trật tự từ khóa: Các hệ thống cũ thường chỉ đếm số lượng từ khóa trùng khớp. Nếu người dùng nhập sai trật tự (ví dụ: "màn đêm tên em" thay vì "tên em màn đêm"), hệ thống vẫn trả về kết quả sai do số lượng từ khóa giống nhau.
- Thiếu ngữ cảnh: Hệ thống gợi ý dựa trên thể loại cứng nhắc (Genre tags) mà bỏ qua sắc thái cảm xúc trong lời bài hát.
- Dữ liệu thiếu nhãn (Unlabeled Data): Dữ liệu thu thập được thiếu các nhãn phân loại về độ phổ biến hay sắc thái, gây khó khăn cho huấn luyện có giám sát.

## II. MỤC TIÊU

Xây dựng một hệ thống gợi ý lai (Hybrid Recommender System) kết hợp:

- Kỹ thuật Phân cụm (Clustering): Để tự động gán nhãn và phân khúc bài hát.
- Xử lý ngôn ngữ tự nhiên (NLP): Để hiểu và tìm kiếm dựa trên nội dung lời bài hát với độ chính xác cao.

## III. BỘ DỮ LIỆU

### 3.1. Thu thập và Mô tả dữ liệu

- Dữ liệu được tổng hợp từ ba nguồn chính là Spotify Charts (để lấy thông tin bài hát, tên ca sĩ, thể loại, lượt nghe) và Genius API (để lấy dữ liệu văn bản lời bài hát), Kaggle (thông tin bài hát, tên ca sĩ, thể loại, lượt nghe, văn bản lời bài hát)
- Số lượng dữ liệu ban đầu: 8926 bài hát
- Sau khi lọc dữ liệu: 883 bài hát.
- Cấu trúc dữ liệu (Schema):

| Thuộc tính   | Kiểu dữ liệu | Ý nghĩa                                         |
|--------------|--------------|-------------------------------------------------|
| track_name   | String       | Tên bài hát (Dùng để định danh và hiển thị).    |
| artist_names | String       | Tên nghệ sĩ (Yếu tố quan trọng trong tìm kiếm). |
| streams      | Integer      | Tổng lượt nghe (Dùng để đánh giá độ phổ biến).  |

|        |        |                                                    |
|--------|--------|----------------------------------------------------|
| genre  | String | Thể loại gốc (Pop, Rap, R&B...).                   |
| lyrics | Text   | Lời bài hát đầy đủ (Dùng cho phân tích ngữ nghĩa). |

### 3.2. Tiền xử lý dữ liệu (Data Preprocessing)

Nhóm thực hiện quy trình làm sạch dữ liệu nghiêm ngặt để loại bỏ nhiễu:

- Xử lý giá trị khuyết: Loại bỏ hoặc điền giá trị mặc định cho các dòng thiếu lời bài hát.
- Chuẩn hóa văn bản:
  - Chuyển toàn bộ về chữ thường (Lowercase) để đồng nhất ("Mưa" và "mưa" là một).
  - Loại bỏ ký tự đặc biệt, dấu câu, icon không mang ý nghĩa ngữ nghĩa bằng biểu thức chính quy.
- Loại bỏ từ rác (Stop Words Removal): Xây dựng danh sách các từ rác tiếng Việt (thì, là, mà, ở, bị, được...) và loại bỏ chúng khỏi lời bài hát, giúp mô hình tập trung vào các từ khóa mang ý nghĩa nội dung.

### 3.3. Kỹ thuật trọng số hóa đặc trưng (Feature Weight Boosting)

Một đóng góp quan trọng của nhóm trong đồ án này là kỹ thuật Weight Boosting. Nếu gộp chung tất cả văn bản, máy học sẽ coi từ trong "Tên bài" có giá trị ngang bằng từ trong "Lời bài hát". Điều này sai với thực tế tìm kiếm.

Nhóm đề xuất công thức tạo văn bản huấn luyện (Training Text) như sau:

$$Text_{final} = (Name \times 3) + (Artist \times 2) + (Genre \times 1) + (Lyrics \times 1)$$

Giải thích:

- Name x3: Nhân bản tên bài hát 3 lần. Điều này làm tăng tần suất xuất hiện của từ khóa trong tên bài, giúp thuật toán TF-IDF đánh giá trọng số cực cao. Hệ quả: Khi người dùng nhập đúng tên bài, bài đó chắc chắn lên Top 1.
- Artist x2: Ưu tiên tìm kiếm theo tên ca sĩ cao hơn tìm theo lời.

### 3.4. Vector hóa văn bản (TF-IDF Representation)

Sau khi tiền xử lý, dữ liệu văn bản được chuyển đổi sang dạng vector số học bằng kỹ thuật TF-IDF (Term Frequency - Inverse Document Frequency). Cấu hình mô hình cụ thể như sau:

- N-gram Range (1, 3): Thay vì chỉ học các từ đơn lẻ (Unigram), mô hình được cấu hình để học cả các cụm từ gồm 2 đến 3 từ (Bigram, Trigram). Ví dụ: mô hình sẽ hiểu cụm "yêu đơn phương" là một thực thể ngữ nghĩa trọn vẹn thay vì tách rời thành "yêu", "đơn", "phương", giúp bảo toàn ngữ cảnh của từ vựng.
- Max Features (10,000): Giới hạn không gian vector ở mức 10.000 đặc trưng quan trọng nhất. Con số này là điểm cân bằng tối ưu giữa hiệu năng tính toán và độ phủ ngữ nghĩa của hệ thống.

## IV. PHÂN TÍCH

### 4.1. Phân cụm dữ liệu không giám sát (K-Means Clustering)

Để giải quyết bài toán dữ liệu thiếu nhãn (Unlabeled Data) – tức là chưa có thông tin phân loại về tâm trạng hay mức độ phổ biến ("Hit" hay "Flop") – nhóm nghiên cứu sử dụng thuật toán K-Means để thực hiện gán nhãn tự động (Auto-labeling).

1. Đặc trưng đầu vào: Mô hình chỉ sử dụng các dữ liệu định lượng và định danh gồm Log (Streams) (quy mô lượt nghe đã chuẩn hóa) và Genre (đã mã hóa One-Hot). Lời bài hát chưa được sử dụng ở bước này để đảm bảo việc phân chia phân khúc hoàn toàn khách quan dựa trên thị hiếu thị trường.
2. Tối ưu hóa tham số K: Sử dụng phương pháp Elbow Method, nhóm xác định điểm gãy tối ưu tại K=4.
3. Kết quả định danh cụm:
  - Cluster 0 - Nhạc R&B Thời Thượng: Các bài hát xu hướng mới, có tiết tấu hiện đại.
  - Cluster 1 - Pop Đại trà: Các bài hát phổ biến ở mức trung bình, dễ nghe.
  - Cluster 2 - Ballad Quốc Dân: Dòng nhạc buồn, sâu lắng, ca từ mang nhiều cảm xúc.
  - Cluster 3 - Top Hits & Rap: Các bài hát có lượt stream "khủng" hoặc đặc trưng dòng nhạc Rap sôi động.

#### 4.2. Mô hình Dự báo & Phân loại Ý định (User Intent Prediction Model)

Thay vì chỉ phân tích từ khóa đơn thuần, nhóm xây dựng một mô hình học máy để dự báo (predict) xem câu nhập của người dùng thuộc về nhóm tâm trạng hay dòng nhạc nào.

- Thuật toán sử dụng: Multinomial Naive Bayes.
- Cơ chế Dự báo:
  - Mô hình được huấn luyện để học xác suất xuất hiện của các từ khóa trong từng cụm (Cluster) đã được gán nhãn ở bước 4.1.
  - Input: Một câu văn bản bất kỳ (VD: "Hôm nay trời mưa buồn quá").
  - Process: Mô hình tính toán xác suất để xem câu này "gần" với đặc trưng ngôn ngữ của cụm nào nhất.
  - Output (Dự báo): Hệ thống dự đoán câu này thuộc Cluster 2 (Ballad/Tâm trạng) với độ tin cậy (Confidence score) ví dụ là 89%. Vai trò: Giúp hệ thống "hiểu" được nhu cầu ẩn của người dùng ngay cả khi họ không gõ tên bài hát cụ thể, từ đó khoanh vùng dữ liệu cần tìm kiếm.
- Vai trò: Giúp hệ thống "hiểu" được nhu cầu ẩn của người dùng ngay cả khi họ không gõ tên bài hát cụ thể, từ đó khoanh vùng dữ liệu cần tìm kiếm.

#### 4.3. Mô hình Tìm kiếm & Truy xuất Thông tin (Hybrid Search & Retrieval Model)

Hệ thống tìm kiếm không chỉ dựa trên một chỉ số. Nhóm phát triển thuật toán xếp hạng dựa trên 2 thành phần:

1. Độ tương đồng ngữ nghĩa (Cosine Similarity):
  - Sử dụng độ tương đồng Cosine Similarity trên không gian vector TF-IDF.
  - Chức năng: Tìm kiếm dựa trên sự trùng lặp về nội dung và ngữ cảnh. Lớp này hoạt động tốt khi người dùng nhập sai chính tả hoặc tìm kiếm theo chủ đề rộng.

$$\text{Cosine}(Q, D) = \frac{Q \cdot D}{\|Q\| \times \|D\|}$$

2. So khớp chuỗi tuần tự (Sequence Matching Score)

- Đặt vấn đề: Các phương pháp tìm kiếm truyền thống (như đếm từ khóa - Bag of Words) thường gặp hạn chế lớn là bỏ qua trật tự của từ (Word Order). Ví dụ, nếu người dùng nhập sai trật tự như "màn đêm tên em" (thay vì "tên em màn đêm"), hệ thống cũ vẫn chấm điểm cao do số lượng từ khóa trùng khớp là như nhau. Điều này làm giảm độ chính xác của trải nghiệm tìm kiếm lời bài hát (Lyrics Search).
- Giải pháp kỹ thuật: Để khắc phục, nhóm nghiên cứu áp dụng thuật toán So khớp chuỗi tuần tự (Sequence Matching) kết hợp với kỹ thuật Cửa sổ trượt (Sliding Window).
- Cơ chế hoạt động: Thay vì so sánh câu truy vấn với toàn bộ lời bài hát (gây lãng phí điểm số), hệ thống thực hiện quy trình sau:
  - Sliding Window: Tạo một "cửa sổ" có độ dài tương đương với câu truy vấn của người dùng.
  - Scanning: Trượt cửa sổ này dọc theo toàn bộ văn bản lời bài hát.
  - Local Matching: Tại mỗi vị trí cửa sổ, sử dụng thuật toán `difflib.SequenceMatcher` để tìm ra chuỗi ký tự chung dài nhất (Longest Common Substring).
- Mục đích: Thuật toán này đóng vai trò là "bộ lọc tinh" (Fine-tuning filter). Nó trừng phạt nặng các kết quả có từ khóa nhưng sai trật tự hoặc nằm rời rạc, đồng thời đẩy các bài hát có đoạn lời khớp chính xác 100% về mặt cấu trúc lên vị trí ưu tiên (Rank 1). Sự kết hợp giữa Cosine Similarity (hiểu ngữ nghĩa rộng) và Sequence Matching (hiểu trật tự chính xác) tạo nên sức mạnh của mô hình Hybrid.

## V. KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

Nhóm nghiên cứu tập trung đánh giá hiệu năng của hai thành phần cốt lõi trong hệ thống:

1. Mô hình Dự báo Ý định (Intent Prediction Model): Khả năng phân loại đúng nhu cầu người dùng.
2. Mô hình Tìm kiếm (Search Engine): Độ chính xác của kết quả trả về.

### 5.1. Đánh giá Mô hình Dự báo & Phân loại

Mô hình Multinomial Naive Bayes được đánh giá dựa trên khả năng dự đoán đúng nhãn phân khúc (Cluster Label) từ dữ liệu lời bài hát.

- Phương pháp kiểm thử: Sử dụng kỹ thuật K-Fold Cross Validation (Kiểm thử chéo) chia tập dữ liệu theo tỷ lệ 60% Huấn luyện - 40% Kiểm thử.
- Chỉ số đo lường chính:
  - Độ chính xác tổng thể: Đạt mức ~60% trên tập dữ liệu chưa cân bằng.
  - Độ chính xác theo lớp:
    - Nhóm Ballad (Cluster 2) và Rap (Cluster 3): Đạt độ chính xác rất cao (>85%). Điều này cho thấy mô hình học rất tốt các đặc trưng ngôn ngữ riêng biệt (từ vựng cảm xúc buồn của Ballad hoặc từ lóng/tiếng Anh của Rap).
- Phân tích sai số:
  - Sự nhầm lẫn chủ yếu xảy ra giữa nhóm Pop (Cluster 1) và R&B/Trend (Cluster 0).
  - Nguyên nhân: Do sự giao thoa lớn về phong cách sáng tác hiện đại, các bài hát Pop và R&B thường sử dụng chung một tập từ vựng (common vocabulary), khiến mô hình xác suất khó phân định ranh giới rõ ràng.

### 5.2. Đánh giá Hiệu năng Hệ thống Tìm kiếm

Hệ thống Hybrid Search (kết hợp Sequence Matching & Cosine) được đánh giá thông qua các kịch bản kiểm thử (Test Scenarios) mô phỏng hành vi thực tế của người dùng, nhằm kiểm chứng độ chính xác và khả năng xếp hạng ưu tiên.

## VI. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

### 6.1. Kết luận

Đồ án đã thiết kế và hiện thực hóa thành công quy trình xử lý dữ liệu khép kín:

1. Sử dụng **K-Means** như một công cụ gán nhãn tự động, giải quyết vấn đề Cold-Start khi thiếu metadata.
2. Kết hợp **TF-IDF**, **Naive Bayes** và cơ chế **Hybrid Ranking** để tạo ra công cụ tìm kiếm hiểu được cả ngữ nghĩa và nhu cầu chính xác của người dùng.

### 6.2. Hạn chế và Hướng phát triển

- **Dữ liệu:** Cần mở rộng bộ dữ liệu lên >2000 bài hát để làm phong phú từ điển (Vocabulary), giúp hệ thống bắt được các từ khóa hiếm tốt hơn.
- **Công nghệ:** Trong tương lai, nhóm đề xuất thay thế TF-IDF bằng các mô hình ngôn ngữ lớn (LLM) hoặc **PhoBERT** (VinAI) để vector hóa, giúp hệ thống hiểu sâu hơn các phép ẩn dụ, đồng nghĩa trong tiếng Việt.

*Tài liệu tham khảo:*

1. *Scikit-learn Documentation (TF-IDF, Naive Bayes, K-Means).*
2. *Manning, C. D., et al. (2008). Introduction to Information Retrieval. Cambridge University Press.*